# Informe de Análisis de Datos

Healthcare Dataset · Exploración, Diagnóstico y Limpieza

| 55,500 | 54,860 | 640 | 15 |
|---|---|---|---|
| Registros originales | Registros limpios | Filas eliminadas | Columnas |

Cobertura temporal: 2019–2024 · Fuente: Kaggle / prasad22/healthcare-dataset

# FASE 1 EXPLORACIÓN Y DIAGNÓSTICO DEL DATASET

## 1. Descripción General

El dataset simula registros de hospitalización con 55,500 filas y 15 columnas. Cubre información demográfica (nombre, edad, género, tipo de sangre), clínica (condición médica, medicamento, resultados de pruebas), logística (hospital, médico, habitación, tipo de admisión, fechas de ingreso y alta) y financiera (monto de facturación, aseguradora).

| Columna | Tipo raw | Categorías / Rango |
|---|---|---|
| Name | object | Nombres con casing aleatorio y prefijos de título |
| Age | int64 | 13 – 89 años |
| Gender | object | Male, Female |
| Blood Type | object | 8 grupos: A+, A-, B+, B-, AB+, AB-, O+, O- |
| Medical Condition | object | 6 condiciones: Cancer, Diabetes, Obesity, Asthma, Hypertension, Arthritis |
| Date of Admission | object* | String YYYY-MM-DD (rango: 2019-05-08 a 2024-05-07) |
| Doctor | object | Nombres de médicos |
| Hospital | object | Aproximadamente 39,876 valores únicos — fragmentado |
| Insurance Provider | object | 5 aseguradoras: Aetna, Blue Cross, Cigna, Medicare, UnitedHealthcare |
| Billing Amount | float64 | -2,008.49 a 52,764.28 (incluye valores negativos) |
| Room Number | int64 | 101 – 500 |
| Admission Type | object | Urgent, Emergency, Elective |
| Discharge Date | object* | String YYYY-MM-DD |
| Medication | object | 5 medicamentos: Aspirin, Ibuprofen, Lipitor, Paracetamol, Penicillin |
| Test Results | object | Normal, Abnormal, Inconclusive |

* Almacenadas como texto — requieren conversión a datetime para habilitar operaciones temporales.

# 2. Diagnóstico de Calidad de Datos

## 2.1 Valores Nulos

El dataset no presenta ningún valor nulo en ninguna de sus 15 columnas. Esto es consistente con datos de origen sintético y simplifica el proceso de limpieza al no requerir imputación.

| Estado | Columnas afectadas | Observación |
|---|---|---|
| Sin valores nulos | 15 / 15 | No se requiere estrategia de imputación. Se recomienda verificar strings vacíos con str.strip() como precaución adicional. |

## 2.2 Duplicados Exactos

Se detectaron 534 filas completamente duplicadas (representadas como 1,068 en la vista keep=False). Esto equivale al 0.96% del total del dataset. Los registros son idénticos en todos sus campos, incluyendo monto de facturación, médico y hospital asignado, lo que descarta que correspondan a reingresos legítimos.

| Nombre | Edad | Condición | Fecha Ingreso | Billing ($) |
|---|---|---|---|---|
| ABIgaIL YOung | 41 | Hypertension | 2022-12-15 | 1,983.57 |
| ALIcia taYLoR | 78 | Asthma | 2022-09-18 | 31,465.27 |
| willIAM DUnCan | 78 | Arthritis | 2019-08-04 | 4,537.85 |
| zaCHAry balL | 85 | Diabetes | 2020-04-25 | 15,207.55 |

## 2.3 Tipos de Datos Incorrectos

Las columnas de fecha están almacenadas como tipo object (string). Esto impide calcular duraciones de estadía, filtrar por períodos o extraer componentes de fecha como año o mes.

| Columna | Tipo actual | Tipo correcto | Consecuencia si no se corrige |
|---|---|---|---|
| Date of Admission | object | datetime64[ns] | Imposible calcular días de estadía o filtrar por año/mes |
| Discharge Date | object | datetime64[ns] | Imposible calcular la duración de cada hospitalización |

## 2.4 Capitalización Aleatoria en Nombres

La totalidad de los registros presenta nombres con capitalización irregular. Este problema afecta directamente la detección de duplicados por nombre y cualquier operación de agrupación o búsqueda sobre el campo Name.

| Nombre en crudo | Nombre correcto esperado |
|---|---|
| Bobby JacksOn | Bobby Jackson |
| CHrisTInA MARtinez | Christina Martinez |
| EMILY JOHNSOn | Emily Johnson |
| jAMES GARCiA | James Garcia |
| eLIZABeTH jaCkSOn | Elizabeth Jackson |

## 2.5 Prefijos de Título en Nombres

352 registros incluyen prefijos de tratamiento (Mr., Mrs., Ms., Dr., y variantes con casing mixto) incorporados directamente en el campo Name. Esto genera inconsistencias al identificar pacientes, ya que el mismo individuo podría aparecer con y sin prefijo como registros distintos.

| Nombre con prefijo | Prefijo detectado |
|---|---|
| Mr. eRiC Lane | Mr. |
| mR. DAVID pIERce Md | mR. |
| Dr. LEONarD BrEWEr Ii | Dr. |
| MS. nAtalIE gAMble | MS. |
| mRS. jamiE cAMPBELl | mRS. |

## 2.6 Billing Amount — Valores Negativos y Extremos

La columna Billing Amount presenta tres rangos de valores que requieren análisis:

| Tipo de anomalía | Cantidad | Rango | Decisión tomada |
|---|---|---|---|
| Valores negativos | 108 | -2,008.49 a -0.01 | Eliminados — inválidos en facturación hospitalaria |
| Valores menores a $100 | 130 | $9.24 a $99.99 | Conservados — pueden corresponder a servicios menores |
| Valores mayores a $50,000 | 458 | $50,000 a $52,764 | Conservados — dentro del rango plausible del dataset |

## 2.7 Campo Hospital — Alta Fragmentación

Con aproximadamente 39,876 valores únicos para 55,500 registros, el campo Hospital refleja la naturaleza sintética del dataset: los nombres fueron generados con variaciones aleatorias que incluyen comas mal posicionadas, guiones arbitrarios y conectores como 'and' en posiciones inconsistentes. Esto hace que el campo sea prácticamente inutilizable para análisis de agrupación sin una limpieza especializada.

| Nombre original | Problema identificado |
|---|---|
| Hernandez Rogers and Vang, | Coma al final del nombre |

| Nombre original | Problema identificado |
|---|---|
| and Mahoney Johnson Vasquez, | Inicia con 'and' y termina con coma |
| Henry Sons and | Termina con conector 'and' |
| White-White | Guión innecesario entre palabras |
| Powell Robinson and Valdez, | Coma al final del nombre |

### 2.8 Pacientes Menores de 18 Años

Se identificaron 116 registros con pacientes menores de 18 años (edad mínima: 13 años), equivalentes al 0.21% del dataset. Un hospital general atiende pacientes de todas las edades, por lo que la presencia de menores es clínicamente plausible y no representa un error del dataset. Se decide conservar estos registros.

## 3. Resumen de Problemas — Fase 1

| N. | Problema | Filas afectadas | Severidad | Tratado en Fase 2 |
|---|---|---|---|---|
| 1 | Duplicados exactos | 534 filas | Alta | Si |
| 2 | Fechas almacenadas como strings | 2 columnas | Media | Si |
| 3 | Capitalización aleatoria en nombres | 55,500 filas | Media | Si |
| 4 | Billing Amount negativo | 108 filas | Alta | Si |
| 5 | Prefijos de título en nombres | 352 filas | Media | Si |
| 6 | Hospital muy fragmentado | ~39,876 únicos | Alta | Parcialmente |
| 7 | Billing Amount menor a $100 | 130 filas | Media | Conservados con justificación |
| 8 | Pacientes menores de 18 años | 116 filas | Media | Conservados con justificación |

# FASE 2 LIMPIEZA Y TRANSFORMACIÓN

## 4. Transformaciones Aplicadas

A continuación se documenta cada transformación ejecutada en el notebook, con su justificación técnica y el resultado verificado en los outputs de cada celda.

### T1 Eliminación de Duplicados Exactos (Celda 15)

```
datase.drop_duplicates(inplace=True)
```

**Justificación:**

- drop_duplicates() compara todas las columnas simultáneamente. Solo se eliminan filas donde cada uno de los 15 campos es idéntico entre sí, por lo que no existe riesgo de descartar reingresos legítimos de un mismo paciente.
- El uso de inplace=True modifica el DataFrame directamente, evitando la creación de una copia intermedia innecesaria.

**Resultado verificado:**

- 534 filas eliminadas: el dataset pasa de 55,500 a 54,966 registros (confirmado en celda 16 con datase.info()).

## T2 Conversión de Fechas a datetime (Celda 17)

```
datase['Date of Admission'] = pd.to_datetime(datase['Date of Admission'])  /
datase['Discharge Date'] = pd.to_datetime(datase['Discharge Date'])
```

**Justificación:**

- pd.to_datetime() transforma las columnas de tipo object a datetime64[ns], habilitando operaciones como resta de fechas, extracción de año/mes/día, agrupaciones temporales y visualizaciones de series de tiempo.
- Todas las fechas tienen formato YYYY-MM-DD consistente, por lo que la conversión no generó errores ni valores nulos adicionales.

**Resultado verificado:**

- Ambas columnas aparecen como datetime64[ns] en el datase.info() de la celda 30, confirmando la conversión exitosa.
- La estadística descriptiva de celda 18 muestra fechas de admisión entre 2019-05-08 y 2024-05-07, y fechas de alta entre 2019-05-09 y 2024-06-06, sin valores anómalos.

## T3 Normalización de Nombres con str.title() (Celda 19)

```
datase['Name'] = datase['Name'].str.title()
```

**Justificación:**

- str.title() convierte cada palabra al formato estándar de nombre propio (primera letra en mayúscula, resto en minúsculas), resolviendo la capitalización aleatoria de forma uniforme y reproducible sobre los 54,966 registros.
- Se aplica antes de la limpieza de prefijos para garantizar que los patrones de regex funcionen de forma predecible, ya que trabajan con texto ya normalizado.

**Resultado verificado:**

| Antes de la transformación | Después de la transformación |
|---|---|
| Bobby JacksOn | Bobby Jackson |
| CHrisTInA MARtinez | Christina Martinez |
| jAMES GARCiA | James Garcia |

| Antes de la transformación | Después de la transformación |
|---|---|
| eLIZABeTH jaCkSOn | Elizabeth Jackson |

## T4 Limpieza de Billing Amount Negativos (Celda 25)

```
datase = datase[datase['Billing Amount'] >= 0].copy() datase.reset_index(drop=True,
inplace=True)
```

**Justificación:**

- Un monto de facturación negativo no tiene interpretación válida en un contexto hospitalario. No existe evidencia de que correspondan a notas de crédito o devoluciones, por lo que se eliminan los 108 registros afectados.
- El uso de .copy() tras el filtrado previene el SettingWithCopyWarning que se presentaba en la versión anterior del notebook, ya que garantiza que datase sea un DataFrame independiente y no una vista del original.
- reset_index(drop=True) restablece el índice de forma continua (0 a 54,859) tras la eliminación de filas, evitando inconsistencias entre iloc y loc en pasos posteriores.

**Sobre los valores menores a $100:**

- Los 130 registros con Billing Amount entre $9.24 y $99.99 se conservan deliberadamente. En un entorno hospitalario real, montos bajos pueden corresponder a copagos de seguro, dispensación de medicamentos ambulatorios, consultas de seguimiento o servicios administrativos de bajo costo. Eliminarlos implicaría descartar información potencialmente válida sin evidencia suficiente de error.

**Resultado verificado:**

- 108 filas eliminadas: el dataset pasa de 54,966 a 54,860 registros.
- El índice confirmado en celda 30 muestra RangeIndex: 54860 entries, 0 to 54859, sin huecos.
- El mínimo de Billing Amount en el dataset limpio es $9.24 y el máximo $52,764.28.

## T5 Eliminación de Prefijos de Título en Nombres (Celda 28)

```
def limpiar_prefijo(nombre):         return re.sub(r'^(mr\.?|mrs\.?|ms\.?|dr\.?|...)', '',
nombre, flags=re.IGNORECASE) datase['Name'] = datase['Name'].apply(limpiar_prefijo)
```

**Justificación:**

- La función aplica una expresión regular al inicio de cada nombre para detectar y eliminar prefijos de título independientemente de su capitalización (mr., Mr., MR., mR.) y con o sin punto final.
- La regex cubre un amplio espectro de prefijos formales (Mr., Mrs., Ms., Dr., Prof., Lic., Ing., Dra., Capt., entre otros) para garantizar que ningún prefijo quede sin eliminar.
- Se usa flags=re.IGNORECASE para no depender de la capitalización, lo que hace la función robusta frente a variaciones como las presentes en el dataset.

**Resultado verificado:**

| Antes de la transformación | Después de la transformación |
|---|---|
| Mr. Eric Lane | Eric Lane |
| Dr. Leonard Brewer | Leonard Brewer |
| Ms. Natalie Gamble | Natalie Gamble |

| Antes de la transformación | Después de la transformación |
|---|---|
| Mrs. Jamie Campbell | Jamie Campbell |

## T6 Limpieza del Campo Hospital  (Celdas 20 y 31)

```
datase['Hospital'] = datase['Hospital'].str.replace('-', ' ', regex=False) datase['Hospital']
= datase['Hospital'].str.replace(',', '', regex=False) datase['Hospital'] =
datase['Hospital'].str.title() datase['Hospital'] = datase['Hospital'].apply(limpiar_and)
```

**Justificación:**

- Reemplazar guiones por espacios unifica variantes como 'Jones-Thompson' con 'Jones Thompson', que son el mismo hospital con distinta notación.
- Eliminar comas sobrantes (por ejemplo 'Vang,') corrige artefactos del proceso de generación sintética del dataset.
- str.title() estandariza la capitalización de todos los nombres de hospital de forma consistente.
- limpiar_and() elimina el conector 'And' cuando aparece al inicio o al final del nombre usando regex con flag IGNORECASE, sin afectar nombres donde 'And' forma parte legítima del medio del nombre (por ejemplo 'Jackson Todd And Castro' se mantiene intacto).

**Resultado verificado:**

| Antes | Despues |
|---|---|
| Hernandez Rogers and Vang, | Hernandez Rogers And Vang |
| and Mahoney Johnson Vasquez, | Mahoney Johnson Vasquez |
| Henry Sons and | Henry Sons |
| White-White | White White |

**Nota sobre la fragmentación restante:**

- El campo Hospital conserva un número elevado de valores únicos tras esta limpieza. La fragmentación proviene de la naturaleza sintética del dataset y no puede resolverse completamente con normalización de texto simple. Para análisis agrupados por institución, se requeriría una técnica de fuzzy matching o la asignación de un identificador canónico de hospital.

## T7 Pacientes Menores de 18 Años (Decision documentada)

**Justificación:**

- Los 116 registros con pacientes menores de 18 anos (0.21% del dataset) se conservan en el dataset limpio. Un hospital general no restringe su atención a adultos: atiende pacientes de todas las edades, desde pediatría hasta geriatría. La presencia de menores es clínicamente plausible y no constituye un error de datos.
- Eliminar estos registros sin evidencia de error introduciría un sesgo artificial al reducir la representación de pacientes jóvenes en el análisis.

# 5. Dataset Limpio — Estado Final

| 54,860 | 640 | 15 | 0 |
|---|---|---|---|
| Registros finales | Filas eliminadas | Columnas | Valores nulos |

| Columna | Tipo final | Estado tras limpieza |
|---|---|---|
| Name | object | Title Case aplicado, prefijos de titulo eliminados |
| Age | int64 | Sin cambios — rango 13 a 89 anos |
| Gender | object | Sin cambios — Male / Female |
| Blood Type | object | Sin cambios — 8 grupos sanguineos |
| Medical Condition | object | Sin cambios — 6 condiciones |
| Date of Admission | datetime64[ns] | Convertido desde string |
| Doctor | object | Sin cambios |
| Hospital | object | Guiones, comas y 'And' extremo eliminados; Title Case |
| Insurance Provider | object | Sin cambios — 5 aseguradoras |
| Billing Amount | float64 | 108 negativos eliminados — minimo $9.24 |
| Room Number | int64 | Sin cambios — rango 101 a 500 |
| Admission Type | object | Sin cambios — Urgent / Emergency / Elective |
| Discharge Date | datetime64[ns] | Convertido desde string |
| Medication | object | Sin cambios — 5 medicamentos |
| Test Results | object | Sin cambios — Normal / Abnormal / Inconclusive |

# 6. Conclusiones

Este notebook **EDA_F1-F2.ipynb** describe cómo se llevó a cabo la limpieza:

- Eliminación de 534 duplicados exactos sin pérdida de información clínica valida.
- Conversión de fechas a datetime64 correctamente aplicada y verificada.
- Normalización de nombres a Title Case de forma uniforme sobre todos los registros.
- Eliminación de 108 registros con Billing Amount negativo usando .copy() y reset_index, resolviendo el SettingWithCopyWarning y el índice discontinuo.
- Limpieza parcial del campo Hospital: comas, guiones y conectores extremos eliminados con justificación documentada.
- Eliminación de prefijos de título con regex robusta e insensible a mayúsculas.
- Decisiones documentadas sobre los valores conservados: Billing Amount menor a $100 (servicios menores) y pacientes menores de 18 años (hospital de atención general).
- Exportación única al final del flujo.